四个概念，四种类型：
智能、人类智能、人工智能、通用人工智能的
层次、边界与转译协议

余玉桂
余玉桂战略研究室
they4897@gmail.com

摘要

智能、人类智能、人工智能、通用人工智能——四个词在文献、政策与产业话语中每天使用，但它们之间的层次与边界至今没有权威版本：仅一部编纂就收录了约七十条智能定义；通用人工智能的定义在 2023 至 2026 年间进入制度化竞争期，产业界则通过系统性换词，避免被自己立下的定义反噬。本文提出双重主张。其一（类型论）：四个词不是一条阶梯上的四级，而是四种不同类型的概念——智能是能力概念、人类智能是样本概念、人工智能是造物概念、通用人工智能是参照系概念；每一类的“定义完成”形态不同，流行的“专用—通用—超级”阶梯是把四类概念串在一条线上的叙事装置。其二（分层论）：每个概念内部须区分本体层（它是什么）、认识层（什么证据支持某系统具有它）与方法层（用什么程序检测它）；定义之争长期难解的根源是三种非法滑动——操作主义（测量冒充定义）、部分谬误（机制冒充能力定位）、判据升格（工程判据冒充概念内容）。本文的核心贡献是一份转译协议：工程观察（电路、特征、梯度、基准得分）到概念命题的转译表，每行附生效条件，附非法转译目录；据该协议，“泛化在权重中”类主张不是错误而是越权——能力谓词的归属层级是系统与环境范围的组合，关系属性本无所谓位置。文末给出四词在 AGI 人本拟合论中的最终位置、证伪条款与中文语境对接。

关键词：智能定义；通用人工智能；构造效度；操作主义；部分谬误；机制解释性；概念分层；AGI 人本拟合论

1 引言

这四个词在人工智能话语中被日日使用，其间的层次关系却从未有过共识。“什么是智能”的问题至少从 1923 年起就没有共识 [1]；Legg 与 Hutter 编纂过的非正式定义约七十条 [2]——定义的数量在一个世纪里增加而非收敛。“什么是通用人工智能”（AGI）使同一困境雪上加霜：2023 至 2026 年，AGI 的定义进入制度化竞争期——性能分级矩阵 [3]、心理测量模型定义 [4]、经济条款定义 [5] 并存而互斥；与此同时，产业与监管话语系统性换词（前沿模型、超级智能、通用目的人工智能），没有任何主要机构愿意受自己五年前的定义约束、对“AGI 是否已经达成”作出裁决。四词之间唯一深入人心的“层次图”——专用人工智能到 AGI 再到超级智能的三级阶梯——是大众惯例而非学术分类，而且，本文将论证，它本身就是概念混淆的载体。

两类日常话语让这种无共识的状态变得刺眼。第一类来自定义侧：大量“定义”实际上是测量方法。“智能就是测验所测的东西”[1] 是这一形态的原型；它的当代变体包括把一个测量泛函当作智能的定义 [6]、把一套评测协议当作通用性的定义 [3, 7]、把一份经济条款当作 AGI 的定义 [5]。第二类来自工程侧：机制解释

性研究在权重、电路与梯度中观察到结构，随后在传播中升格为“泛化、智能就在其中”的断言。本文对这两类话语给出的诊断相同：它们都不是错误命题，而是*越权命题*——把在一层之内合法的主张，未经条件检验就转译到另一层。而“让人难以信服”的结构性原因也在于此：方法冒充定义的命题不可反驳——测试失败永远可以归因于方法（基准污染、分布不匹配、任务集过窄），定义本身从不受伤；一个永不承担失败风险的命题不是认识论主张，是信条。

本文做三件事。第一，把四个词整理成四种概念类型，并说明为什么每一类的“定义完成”形态不同（第 3 节）。第二，给每个概念建立本体层、认识层、方法层的三层结构，把现有定义之争诊断为三种非法滑动，并以一份逐字引语的主张清单为证据底座（第 4 节）。第三，给出一份转译协议——工程观察到概念命题的转译表与非法转译目录（第 5 节）；这是本文的核心贡献：它不禁止跨层转译，而是要求每次转译出示生效条件。第 6 节把四词安放进 AGI 人本拟合论，第 7 节给出证伪条款，附录 A 给出主张清单，附录 B 给出中文语境对接。

本文与同一研究纲领前三篇论文分工明确：理论论文论证了通用性是相对于人类实践开放集的关系属性 [8]，本文把这一结论用作参照系概念的现成理论形式；概念解绑论文区分了人工智能的工程目标与机器之心 [9]，本文把它的“功能智能”用作造物概念的判据；方法论论文的披露审计 [10] 在本文中用作认识层工具的范例。本文的增量贡献是四词的类型学、三层结构与转译协议——经文献检索未见先例（中英文文献中均无，见第 2、2.5 节的空白声明）。

2 定义现状：谱系与漂移

2.1 智能：无共识的世纪

现代讨论仍在引用的两极，早在 1904 至 1923 年间就已成形。一极是心理测量学：Spearman 从“几乎所有认知测验彼此正相关”的统计事实出发提出一般因素 g[11]，由此开启了一条在人类样本内工作得相当好的测量传统。另一极是操作主义立场：Boring 直言“智能就是智力测验所测的东西”[1]——定义即测量操作。Bridgman 在物理学中提出“概念即一套操作”[12] 后，操作主义在物理科学中迅速退潮，却在智能定义史上反复出现（第 4 节）。

形式化传统的代表是 Legg 与 Hutter：“智能衡量的是一个智能体在广泛环境范围内达成目标的能力”[6]，并以对一切可计算环境的加权期望奖励给出形式定义。这一路径把智能定义为一种与载体无关的能力度量，人类智能在该框架内降格为尺度上的一点。与之相对，Chollet 把智能定义为“在给定任务范围、先验与经验条件下获取新技能的效率”[7]，并断言技能只是智能过程的固定产物——不存在这样的任务：仅凭系统在该任务上的技能就足以证明智能。两个定义互相冲突：前者会把一个“买来大量技能”的系统判为高智能，后者判其为高级技能库。一个世纪过去，分歧的形态没有收敛，只是换了词汇。

2.2 人类智能：样本内的共识

对“人类智能”，心理学反而有一份在实务层面足以使用的共识。Cattell–Horn–Carroll 三层模型把能力结构整理为：顶层 g、中层约十个广域能力（流体推理、晶体知识、加工速度、工作记忆等）、底层数十种窄能力 [13]；当代主流智力测验均按该模型设计。两份共识文件给出了引用最广的文字定义：美国心理学会任务组报告 [14] 与五十二名研究者联署的《关于智能的主流科学》[15]。

这份共识的边界常被忽略：它只覆盖智人样本。Legg 与 Hutter 编纂的七十条定义中多数来自心理学家、以人类为样本——“许多智能定义实为人类智能定义”并非修辞，而是可以直接从这部汇编中核实的事实 [2]。Hernández-Orallo 的通用心理测量学系统论证了：以人类为标定参照系的测验，外推到机器与动物时便会失

效 [16]；Chollet 则给出一个重要的反转：人类中心的参照系“不仅合法而且必要”——因为技术为人服务——但必须明确作出声明，把先验与开发者注入计入度量 [7]。也就是说，学界已经承认“智能”一词在人类中心与载体无关两种立场间摇摆，但从未把这一摇摆本身整理成概念类型的区分。这正是本文要做的事。

2.3 人工智能：不定义智能，只定义制造

人工智能的奠基文本有意绕开了智能的定义。达特茅斯提案的纲领句是：学习的每一方面或智能的任何特征，原则上都可以精确描述，从而使机器能够模拟它 [17]——智能是不加定义的初始词项，被定义的是“制造”。McCarthy 本人的正式表述延续这一结构：“人工智能是制造智能机器、尤其智能计算机程序的科学工程” [18]。教科书传统把定义空间整理为“像人一样思维/理性地思维、像人一样行动/理性地行动”的四方矩阵，并选定“理性地行动”一支 [19]；图灵测试一脉则把人设为不可分辨的对手 [20]。

这一“制造优先”结构有一个著名的后门：由于智能本身未被定义，“人工智能”的边界只能随工程成就移动——Tesler 定理“智能就是机器尚未做到之事” [21] 刻画的正是这个否定性、移动的类别。它解释了为什么 McCarthy 的定义能兼容任何具体技术，也预示了本文第 4 节要诊断的第三种滑动：当工程判据（基准、产品、商业成功）足够强势时，它们便会在不知不觉间被当作智能本身的定义。

2.4 通用人工智能：制度化竞争期

AGI 的定义谱系在 2023 年前是学术小传统：Legg 与 Hutter 的定义与“智能”同一条 [6]；Goertzel 把它表述为“在复杂环境中达成复杂目标的能力” [22]。2023 年起进入制度化竞争：GPT-4 的“火花”论文以“广泛认知能力”作隐含定义 [23]；DeepMind 的分级框架给出“性能 × 通用性”矩阵，把“通用”操作化为“达到目标性能阈值的任务范围”，并将当前前沿模型评为“新兴 AGI” [3]；OpenAI 章程给出经济定义——“在大多数具有经济价值的工作上超越人类的高度自主系统” [5]；2025 年，三十三位作者联署的定义以 Cattell–Horn–Carroll 心理测量模型为骨架，把 AGI 定义为“匹配受良好教育的成年人的认知多面性与熟练度” [4]。批评侧，有论证指出 AGI 话语的诸定义“拥抱一系列互不相容的价值与假设” [24, 25]；测量侧，新提案继续涌现 [26, 27, 28]。

同期发生了两重用词漂移：产品与监管语言从 AGI 转向“前沿模型”与“通用目的人工智能”（后者以训练算力阈值推定系统性风险）；实验室叙事从 AGI 转向“超级智能”。定义分歧最终以换词的方式被搁置，而非得到解决。

2.5 中文语境

中文语境为四词提供了两个独有的观察角度。

第一条是术语分工史。心理学自 1924 年陆志韦 [29] 首次修订比纳量表起，固定使用“智力”（智力测验、智商量表）；“人工智能”译名于二十世纪七十年代末传入、八十年代初在学界正式启用，固定使用“智能”。“智力—智能”的学科分工格局沿用至今，辅以科普层面的“智力（基础层）—智能（应用层）—智慧（价值层）”三层递进——但这一三层框架从未得到严格的概念分析。换言之，中文语境对“智能”的分层有长期的直觉，缺的是学理化的层次图。

第二条是政策用词的漂移。2017 年《新一代人工智能发展规划》仅在基础理论布局中提及“通用人工智能” [30]；2023 年北京的地方政策在操作层面把通用人工智能等同于“通用大模型技术体系” [31]——与学理定义（如朱松纯团队的“无限任务、自主定义任务、价值驱动”三特征与通智测试体系 [32]）之间存在显见的落差；以 2025 年政府工作报告为代表的中央文件则完全绕开“通用人工智能”一词，改用“人工智能+”“具身智能”“智能经济”等政策热词 [33]。国内学界的定义性工作自成谱系：张钹的三代人工智能论给

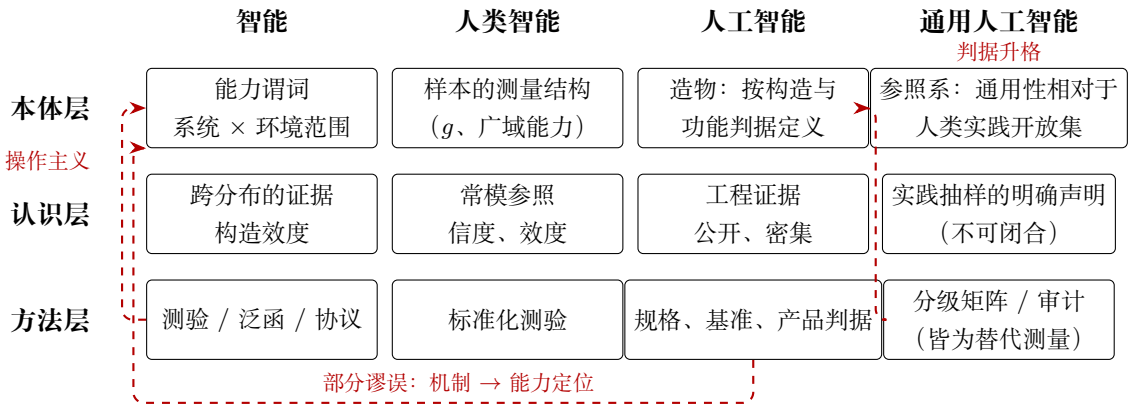


图 1: 四个概念 × 三层结构。列即概念类型（能力、样本、造物、参照系），行即层次（本体层、认识层、方法层）。红色虚线标出第 4 节诊断的三种非法滑动：方法层主张被升格为本体层定义（操作主义）；工程观察被升格为能力的定位（部分谬误）；造物判据被升格为能力定义与参照系内容（判据升格）。

出“专用—通用”的历史分期 [34]；钟义信的机制主义理论给出信息—知识—智能转换的中文原创定义 [35]；哲学侧，刘永谋论证通用人工智能陷入“唯名论困境”——“存在着具体的 AGI 项目，却没有关于 AGI 的一致的定义” [36]；赵汀阳与殷杰则从主体性维度切入 [37]。经文献检索，中文文献中未见以四词层次与边界为题的系统分析（附录 B 给出对话者定位与空白声明）。

2.6 小结：层次的空缺

把谱系合起来看：“智能”有两大互斥定义传统；“人类智能”有样本内共识但常被冒充一般定义；“人工智能”有意不定义智能只定义制造；“通用人工智能”处于定义的制度化竞争期并以换词回避裁决。四词层次关系的权威版本不存在；通用性有四种互不兼容的操作化（任务范围、环境开放性、技能获取效率、自主性等级）；人类智能在 AI 定义中扮演四种角色（参照系、对手、经济计量单位、被批判的标尺）。层次的空缺不是文献不足，而是缺少一个能把这四个词各自属于哪种概念类型说清楚的框架。第 3 节给出这个框架。

3 论题一：四个词，四种概念类型

3.1 判据

本文用以分类的判据是：一个概念的类型由其成功判据的形态决定——即“定义问题已被回答”对它意味着什么。四词在该判据下落入四类（图 1）。

3.2 智能：能力概念

“智能”谓词的归属层级是*系统与环境的组合*：说一个系统有智能，总是相对于一个环境范围而言。Legg 与 Hutter 的形式定义把这一点表述为数学——智能是环境空间上的期望性能 [6]；心理测量学的做法是把它限制在人类所遇任务总体之内。两种进路的共同点：智能的成功判据是*度量形态*——定义问题得到回答，意味着存在一个带构造效度声明的度量。作为一个能力概念，智能不回答“系统由什么构成”，只回答“系统在什么范围内能做到什么”。

3.3 人类智能：样本概念

“人类智能”不是另一个能力，而是一个被测群体的测量结构。它的成功判据是常模形态：定义问题得到回答，意味着对一个有定义的人群存在标准化工具、常模与信效度证据 [11, 13, 14]。样本概念与能力概念的关系是投影而非子集：人类智能是智能概念在智人样本上的投影，带有人群边界——这解释了第 2 节的两件事：为什么心理测量共识不能外推到机器（投影换了样本）[16]，以及为什么“许多智能定义实为人类智能定义”（把投影当成了原象）。

3.4 人工智能：造物概念

“人工智能”是一种造物：按构造与功能判据定义的工程物类别。它的成功判据是工程形态——功能规格达成、可公开检验的性能——不要求“拥有智能”作为成立条件。搜索引擎是人工智能，无论有没有人打算把“智能”谓词授予它。本文纲领的概念解绑论文已给出该层的内容：人工智能的工程目标是服务于人类实践的功能智能，其成功判据公开、密集、持续改进 [9]。关键在“造物”二字的推论：造物概念的判据（好不好用）不定义能力概念的内容（什么是智能）——这一推论在第 4 节成为第三种滑动的诊断依据。

3.5 通用人工智能：参照系概念

“通用人工智能”的类型最反直觉：它不是一个更大的能力，而是一个参照系。理论论文已论证其形式：通用性不是自足的内在属性，而是关系属性——一个系统称得上“通用”，只相对于它所参照的人类实践开放集成立；“通用”参照实践的开放集，“高”参照人类教师的绩效，两者都是需求一方作出的规定 [8]。参照系概念的成功判据不可闭合：它不能被一份规格“定义完成”，只能以明确声明的方式给出——声明参照哪个实践集、以什么抽样近似它。这正是定义分歧无法终结的结构性原因：每一份 AGI 定义实际上都在声明一个参照系（CHC 能力清单 [4]、经济价值工作集 [5]、任务广度阈值 [3]），而参照系之间的分歧不是经验分歧，没有实验能裁决。

3.6 阶梯批判与四关系图

流行的三级阶梯（专用人工智能 →AGI→ 超级智能）把四个概念类型串在一条单变量线上，仿佛存在一个“智能量”沿阶梯增长。按类型论，正确的图景是四种概念加四种关系：人类智能是智能在人类样本上的投影（测量关系）；人工智能是实现智能候选者的造物类别（实现关系）；对人工智能的性能评估调用人类智能作为基准（参照关系）；通用人工智能是对参照系本身的命名（规范关系）。阶梯并非全错，而是范畴拼接：它把“能力的量”（第一级到第三级的纵轴）、“样本的常模”（人类在中间一级）、“造物的判据”（何谓专用）与“参照系的开放性”（何谓通用）焊在了一条线上。由此产生的“进步”叙事——系统沿阶梯上升——正是概念解绑论文所诊断的“进步转账错觉”——把工程进步记作智能增长——在层次图上的翻版 [9]。

3.7 每一类的“定义完成”形态

类型论给出一个直接的推论表：能力概念可以操作定义收尾，但须附构造效度声明（否则退化为操作主义）；样本概念以常模收尾；造物概念以功能规格收尾；参照系概念永不以定义收尾，只能以参照集声明收尾。四份“定义完成”的形态互不可替换——用造物规格去“完成”能力概念（第三种滑动）、用测量去“完成”本体（第一种滑动），都是类型错配。这张推论表同时解释了 AGI 定义竞争期（第 2 节）的全部现象：竞争者各自拿一类概念的“定义完成”形态去回答另一类概念的问题。

4 论题二：三层结构与三种非法滑动

4.1 三层框架

对每一个概念，区分三种主张：**本体层**（它是什么——存在与归属的主张）、**认识层**（什么证据支持“某系统具有它”——证据与推断的主张）、**方法层**（用什么程序检测它——操作与协议的主张）。三层不是同一件事的三种说法：它们有不同的真值条件、不同的失败方式、不同的修改代价。中文哲学话语对本体论—认识论—方法论三分有教科书级的稳定用法，本文直接沿用，并将每一处“× 在 × 层”的断言约束在该层内。

图 1 的矩阵是本文的工作图。定义之争的长期症结在图中表现为三种跨层滑动。

4.2 滑动一：操作主义——测量冒充定义

操作主义“概念即一套操作”的主张 [12] 在物理科学中已经退潮；这笔代价，心理测量学最先付出：测验确实测到了某个东西，但测验本身无法说明那是什么——Cronbach 与 Meehl 为此发明“构造效度”与“法则网络”来补救 [38]。AI 的定义史中，这一教训三次重演。第一次：一个测量泛函（环境空间上的期望奖励）被当作智能的定义 [6]。第二次：一套评测协议（技能获取效率、分级矩阵）被当作通用性的定义 [7, 3]。第三次：一份经济条款被当作 AGI 的定义 [5]。

这里先作一处术语区分：分级框架标题中的“操作化”（operationalizing）[3] 是评测工程的中性用法——把抽象目标翻译为可测指标；本文批评的操作主义是 Bridgman 意义上的——把测量操作当作概念的全部内容。前者必要，后者越权；两者的分界正是认识层：评测工程停留在方法层并向认识层提交证据；操作主义跳过认识层，直接用方法层主张回答本体层问题。

操作主义定义的结构性缺陷在于它不可反驳。测试失败永远可以归因于方法——基准污染 [39]、度量选择 [40]、任务集过窄——而“定义”本身从不受伤。一个不承担失败风险的命题不是认识论主张。这也解释了引言中的那个直觉：“把方法论当认识论”的定义让人难以信服，因为信条不参与经验检验。

转机出现在 2021 至 2025 年：测量理论正以制度化的方式进入 AI 评测——基准的构造效度批评 [41]、“涌现是度量伪影”的实证 [40]、克隆基准暴露的过拟合 [39]，直到 2025 年多篇论文把心理测量学的效度框架正式引入大模型评测 [42, 43, 44, 45, 46]。这条线为本文提供了最直接的支撑，但它全部停留在“评测—能力”链接上；经文献检索，未见把效度批评上推到“定义”层的系统诊断——这正是本文要填补的空白。哲学侧最接近的先行者是“AI 操作主义”的诊断 [47]——它论证机器学习实践把概念与操作化等同从而“暂时固定了指称”；本文与它方向相反：不是描述这一现象，而是给出防止它的分层规则与转译协议。

4.3 滑动二：部分谬误——机制冒充能力定位

第二种滑动发生在工程侧。Bennett 与 Hacker 的“部分谬误”（mereological fallacy）诊断：把整体层面的谓词归属于部分——“大脑思考”式的范畴错误 [48]。该诊断已被引入 AI 的“模型在思考”类语义归因讨论 [49, 50]，但尚未用于能力话语与评测分数的层次混淆——本文补上这一步。

论证分三步。第一，能力谓词的归属层级是系统与环境范围的组合（第 3 节）——“系统在环境范围 E 内具有能力 C”的主语永远是系统，不是权重、电路或梯度。第二，通用性是关系属性 [8]，而关系属性没有位置：说“泛化在权重中”不是错了，而是把一个不可定位的属性当成了可定位的东西——如同说“重量在公斤里”。第三，机制解释性研究合法产出的是机制归因与实现证据：找到某能力的实现机制（realizer），不等于给该能力找到了住所（location）——实现者携带倾向，倾向相对于任务分布成立，能力归属仍留在系统层。

为避免把转述的强化版本当作批评对象，本文以逐字引语建立被诊断对象的表述强度光谱（完整清单见

附录 A)。纲领级：“特征是神经网络的基本单位” [51]——原文以思辨命题的形式提出，但它断言的是解释的基本单位在权重里，尚未断言能力在权重里。因果级：“归纳头是小规模纯注意力模型中上下文学习的主要机制” [52]——限定范围内有消融证据支持的机制归因，合法；同文摘要的措辞则谨慎得多——“归纳头可能构成该机制的初步且间接的证据”。实现级：“我们完整逆向工程了这些网络学到的算法”与三阶段中的“电路形成” [53]——对玩具任务成立的最字面版本。许可级：“归因图给出的是关于底层模型中机制的假设”“这些例子是存在性证明” [54]——作者自己把主张限制在认识层。描述级：“该概念宇宙在三个层次上有有趣的结构” [55]——几何观察，未做概念断言。

光谱之外是漂移。同一家机构的论文正文说“我们不能用归因图对底层模型得出确定性结论” [54]，面向公众的博客却说“我们发现 Claude 会提前规划” [56]——标题、正文、传播三级中，措辞强度逐级放大；社区转述再去掉限制词，把“可能是机制”转述成“就是机制”。实证侧已有反例：功能向量头而非归纳头主导较大模型的上下文学习 [57]；稀疏自编码器找不到规范的分析单元 [58]、跨层特征在版本间漂移而电路有效性随之下降 [59]；探针高分不等于表征中有结构 [60, 61]；子空间补丁可制造“可解释性的错觉” [62]；因果探针方法在完备性与选择性间权衡 [63]。哲学侧，对机制解释的哲学研究已起步：有的论证链接不确定性比透明性更关键 [64]，有的区分透明的层次 [65]，有的规范机制发现的策略 [66]，另有“机制解释性需要哲学”的倡言 [67] 与解释的数学哲学 [68]，以及最接近本文的“因果主张必须披露识别假设” [69]。但这些工作各覆盖一角——单点实证反证、探针限度、因果识别——没有人对“观察到结构 → 能力在其中”这一推断形式本身做分层诊断。

4.4 滑动三：判据升格——造物判据冒充能力定义

第三种滑动的后门在奠基文本中就已经打开：人工智能“制造优先”的定义结构（第 2 节）把智能留作不加定义的初始词项。工程由此获得了一个正当的空间：不定义智能，只交付功能。但当造物的工程判据足够强势时——基准登顶、产品成功、经济回报——判据会溢出造物层，被当作能力概念乃至参照系概念的内容：把基准得分读作“智能水平”，把经济替代读作“通用性达成” [5]。与滑动一的区别在于载体：滑动一是“测量冒充定义”，滑动三是“工程目标冒充概念内容”；前者发生在概念的理论侧，后者发生在概念的应用侧。两者共享同一个缺口：跳过认识层——基准得分到能力主张之间缺构造效度声明 [41, 42]，经济替代到通用性主张之间缺实践抽样声明 [8]。

5 转译协议

5.1 为什么需要一份协议

跨层转译本身并无不正当之处。工程观察必须能够进入概念层面的讨论——否则解释性研究与评测科学都失去意义；概念层面的讨论也必须能够约束工程——否则定义之争只是学院游戏。问题在于转译目前是隐含发生的：最成熟的案例是 2025 年的 CHC 定义 [4]——它事实上完成了一次从心理测量模型到 AGI 概念的转译，但没有任何明确的转译方法论：读者看不到哪些心理学限制条件被带入、哪些被丢弃。转译协议的目的不是禁止转译，而是让每次转译出示条件。它把本纲领方法论论文中的“术语对照”升格为一种方法论：那一篇做的是词与词的跨群体对照——把“采样轨迹（rollout）”对照为“实践流遥测” [10]；本篇做的是命题与命题的跨层对照——工程观察陈述到概念命题，附生效条件与非法目录。

5.2 转译表

表 1 给出协议主体：六类常见工程观察，各自许可的概念命题与转译生效条件。

表 1: 转译协议：工程观察 → 概念命题的生效条件。

工程观察陈述	可转译成的概念命题	生效条件
消融电路 c 后任务 T 的表现下降	c 是系统在 T 上的一个贡献机制（方法层主张）	干预的完备性—选择性权衡已报告 [63]；因果识别假设已披露 [69]
探针从表征中解码出特征 f	表征中存在 f 的可解码信息	控制任务选择性检验通过 [60]；解码不等于被使用（遗忘式探测）[61]
特征空间出现几何结构（叶、晶体、方向）	特征空间有描述性结构（描述级）	结构的稳定性跨训练种子与字典尺寸检验 [58]；不得转译为“概念居住于此”
模型在基准 B 上得分 S	相对 B 的任务分布，系统有表现 S	B 附构造效度声明（测的是什么）与污染检查 [42, 39]；不得转译为“智能为 S”
系统在经济价值任务集 W 上达到人类水平	W 上的替代证据（认识层）	W 须明确声明为人类实践开放集的抽样 [8]；抽样方式可审计 [10]
训练中出现相变（如“延迟泛化”，grokking[70]）	训练动力学的一个阶段转变	相变的度量稳定性已检验 [40]；不得自动转译为“泛化已在权重中形成” [53]

协议的每行共享三条总则。其一，*归属保持*：转译后的主语仍是系统（或系统与环境范围的组合），绝不变为权重、电路、梯度。其二，*条件随行*：命题离开方法层时，它的生效条件一起走；无条件的概念命题是越权命题。其三，*分层落位*：转译产出的命题须标注落位层——方法层主张（机制、信息）、认识层主张（证据、替代）、本体层主张（仅当条件全部满足且构造效度成立）。

5.3 非法转译目录

与转译表相对，四种反复出现的非法形式：**定位式**（“智能/泛化在 X 中”）——给关系属性安位置，部分谬误；**整体错置式**（把系统层谓词归属于组件）——归属层级错误；**升格式**（“得分 S” → “智能为 S”、“通过协议 P” → “定义即 P”）——跳过构造效度，操作主义；**普遍化式**（从受测分布跳到开放集）——跳过抽样声明，把投影当原象。目录与转译表逐条相应：每一条非法形式都是某一条合法转译去掉生效条件后的产物。

5.4 对 AGI 定义的推论：定义的三层写法

协议对定义侧的推论：一份负责任的 AGI 定义应写成三层，而不是一句话。本体层：通用性是相对哪个实践集的关系属性（参照系声明）[8]；认识层：什么证据算“达到”——任务集、人群基准、时间窗口（认识声明）[3, 4]；方法层：用什么程序测、抽样如何声明、失效条件是什么（方法声明）[43, 10]。以此重读现有定义：分级矩阵是认识层与方法层上的扎实成果，但以“操作化”之名回答了本体层问题 [3]；CHC 定义是本体层的一次认真声明，但未声明其样本投影的边界（CHC 是人类智能的样本结构，第 3 节）；经济定义是方法层的一纸合同，被当作了本体层裁决 [5]。三层写法不消灭定义分歧——参照系之间的分歧没有实验裁决——但它让每一处分歧落到自己所属的层：可以点名、可以比较、可以撤回。

6 在人本拟合论中的位置

四词的最终图景在 AGI 人本拟合论中获得位置，也反过来支撑该理论。理论论文论证：AGI 是参照系概念（通用性相对于人类实践开放集）、其实现手段是对实践的拟合、其规范位置是增强性工具 [8]。本文补全其概念底座：智能作为能力概念之所以是关系性的，是因为能力由拟合对象与实践范围共同定义——“发生上，这种智能靠拟合实践而获得” [8]；人类智能作为样本概念，是拟合论中人类参照系的测量面；人工智能作为造物概念，其判据（功能智能服务人类实践）已由概念解绑论文固定 [9]——而该论文的“评估的不对称”（能力侧判据公开、机器之心一侧无共识测试）在本文的分层论中获得解释：能力谓词既有明确的系统层归属，又有现成的构造效度程序，而关于心的谓词缺少第三人称测试，故两轨分立。方法论论文的披露审计 [10] 则示范了方法层的正确形态：不宣布测到了通用性，而是就其对八条流水线所披露的抽样方式与逐格证据作出声明——转译条件随行。

对四词的最终定位，一句话：**智能问度量，人类智能问常模，人工智能问造物判据，通用人工智能问参照系**。四个问题不能互相代替，正如四个概念不在一条阶梯上。

7 证伪条款

本文的三个主张各自可被驳倒。**类型论**：若未来工作证明四词可由单一标尺有意义地度量——一个度量同时对智能的能力结构、人类智能常模、人工智能的工程判据与 AGI 的参照集有不失真的预测力——则四类合并，类型论退化为一张多余的分类表；给出该度量的文献将取代本文。**分层论**：若发现某类能力谓词可以合法地归属于组件——即存在“组件级能力”的严格定义与不受反例动摇的判据——则部分谬误诊断失效，“泛化在权重中”从越权命题升格为待检验命题；机制解释性的进展若走到这一步，本文便成为被超越的先行者。**转译协议**：若四种非法转译形式之一被证明在可声明的条件下可靠（定位式在某种关系属性的可定位子类中成立，或升格式在某种自校准基准上成立），则目录相应行撤销、转译表相应扩充——协议自身附有可修订条款。空白声明同样可证伪：若存在中英文文献已做四词层次与边界的系统分析（以“概念类型”或等价框架），本文的增量贡献主张撤回，转为引用。

8 结论

四个词，四种概念，三层结构，一份协议。本文的诊断是：智能定义一个世纪不收敛、AGI 定义以换词回避裁决、工程话语把智能装进权重、公共话语难以取信于人——这四件事是同一种结构性缺陷的四种表现：概念主张在类型之间与层次之间未出示条件便滑动。类型论把四个词放回各自的座位；分层论给每个座位装上真值条件；转译协议在座位之间设了关卡——不是禁止通行，是查验证件。对工程侧，协议的产出是更诚实的强主张：机制归因、存在性证明、分布内倾向，每一件都值得做、值得说，只是不可冒充能力的住所。对定义侧，协议的产出是三层写法：参照系声明、认识声明、方法声明，各落各层，各赌各的证伪。对中文语境，本文补上一直缺少的那张图——“智力—智能—智慧”的直觉分层终于有了概念类型的学理形式。最终，四词在 AGI 人本拟合论中各就其位：智能是靠拟合实践而获得的能力，人类智能是参照系的测量面，人工智能是承载拟合的造物，通用人工智能是那个以人类实践开放集为准的、永不闭合的参照系本身。

参考文献

[1] Edwin Garrigues Boring. Intelligence as the tests test it. *The New Republic*, 35:35–37, 1923.

[2] Shane Legg and Marcus Hutter. Definitions of intelligence, 2007.

[3] Meredith Ringel Morris, Jascha Sohl-dickstein, Noah Fiedel, Nicholas Carlini, Rishabh Pfau, Jacob Lindenberger, Kush Kulkarni, Ann Lee-Taulbee, Adam Eikenberry, Kunal Doshi, Miguel Vega, et al. Levels of AGI: Operationalizing progress on the path to AGI, 2023. ICML 2024; arXiv v2 改题为 "Levels of AGI for Operationalizing Progress on the Path to AGI".

[4] Dan Hendrycks, Yizhou Song, Christian Szegedy, Xuandong Song, Ting Chen, Kevin McGrew, Gary Marcus, Max Tegmark, Ludwig Schmidt, Yoshua Bengio, et al. A definition of AGI, 2025.

[5] OpenAI. Openai charter. openai.com/charter, 2018.

[6] Shane Legg and Marcus Hutter. Universal intelligence: A definition of machine intelligence. *Minds and Machines*, 17(4):391–444, 2007. doi: 10.1007/s11023-007-9079-x.

[7] François Chollet. On the measure of intelligence, 2019.

[8] Yugui Yu. Fitting the practice, not the works: A human-referential theory of AGI（拟合实践，而非作品：AGI 人本拟合论）, 2026.

[9] Yugui Yu. Two different goals: Dissociating the machine mind from artificial intelligence（两个不同的目标：机器之心与人工智能的概念解绑）, 2026.

[10] Yugui Yu. Fitting the practice: A data methodology for frontier model training（拟合实践：前沿模型训练的数据方法论）, 2026.

[11] Charles Spearman. "general intelligence," objectively determined and measured. *American Journal of Psychology*, 15(2):201–293, 1904.

[12] Percy Williams Bridgman. *The Logic of Modern Physics*. Macmillan, New York, 1927.

[13] Kevin S. McGrew. Carroll's three-stratum (3s) cognitive ability theory at age thirty: Important contributions, enduring challenges, and unresolved issues. *Journal of Psychoeducational Assessment*, 41(2): 129–157, 2023.

[14] Ulric Neisser, Gwyneth Boodoo, Jr. Bouchard, Thomas J., A. Wade Boykin, Nathan Brody, Stephen J. Ceci, Diane F. Halpern, John C. Loehlin, Robert Perloff, Robert J. Sternberg, and Susana Urbina. Intelligence: Knowns and unknowns. *American Psychologist*, 51(2):77–101, 1996.

[15] Linda S. Gottfredson. Mainstream science on intelligence: An editorial with 52 signatories, history, and bibliography. *Intelligence*, 24(1):13–23, 1997. 原版刊于 Wall Street Journal, 1994-12-13.

[16] José Hernández-Orallo. *The Measure of All Minds: Evaluating Natural and Artificial Intelligence*. Cambridge University Press, Cambridge, 2017.

[17] John McCarthy, Marvin L. Minsky, Nathaniel Rochester, and Claude E. Shannon. A proposal for the Dartmouth summer research project on artificial intelligence. Stanford University, 1955. URL `http://jmc.stanford.edu/articles/dartmouth/dartmouth.pdf`.

[18] John McCarthy. What is artificial intelligence? Stanford University formal reasoning group, 2007. URL http://jmc.stanford.edu/articles/whatisai/whatisai.html.

[19] Stuart Russell and Peter Norvig. *Artificial Intelligence: A Modern Approach*. Pearson, Hoboken, NJ, 4 edition, 2021.

[20] Alan M. Turing. Computing machinery and intelligence. *Mind*, 59(236):433–460, 1950.

[21] Larry Tesler. The AI effect [essay]. nomodes.com, 1997. URL https://nomodes.com/.

[22] Ben Goertzel. Artificial general intelligence: Concept, state of the art, and future prospects. *Journal of Artificial General Intelligence*, 5(1):1–48, 2014.

[23] Sébastien Bubeck, Varun Chandrasekaran, Ronen Eldan, Johannes Gehrke, Eric Hörenbaum, Senthil Kalyan, Gagan Kamath, Yin Tat Lee, Yuanzhi Li, Scott Nguyen, Nikhil Saunshi, et al. Sparks of artificial general intelligence: Early experiments with GPT-4, 2023.

[24] Borhane Blili-Hamelin, Leif Hancox-Li, and Jessica Smart. Unsocial intelligence: An investigation of the assumptions of AGI discourse, 2024.

[25] Borhane Blili-Hamelin, Kerso Gichiza, Leif Hancox-Li, Jessica Smart, Shengle Zhen, and Thomas Visser. Stop treating "AGI" as the north-star goal of AI research, 2025.

[26] Pei Xu. What is meant by AGI? on the definition of artificial general intelligence, 2024.

[27] Arjun Dhar, Lennart Oldenburg, and Andreas Soegaard. On the measure of a model: From intelligence to generality, 2025.

[28] Gilles E. Gignac and Erik B. Szodorai. Defining intelligence: Bridging the gap between human and artificial perspectives. *Intelligence*, 104:101832, 2024.

[29] 张厚粲 and 骆方. 中国心理和教育测量发展. *Chinese/English Journal of Educational Measurement and Evaluation*（教育测量与评估双语期刊）, 1(1):8, 2020. doi: 10.59863/HOYB3108.

[30] 中华人民共和国国务院. 新一代人工智能发展规划（国发〔2017〕35 号）. 中国政府网, 2017. URL http://www.gov.cn/zhengce/zhengceku/2017-07/20/content_5211996.htm.

[31] 北京市人民政府. 北京市促进通用人工智能创新发展的若干措施. 北京市人民政府, 2023.

[32] 朱松纯 et al. 通用人工智能标准、评级、测试与架构. 人民邮电出版社, 北京, 2025.

[33] 国务院总理. 2025 年政府工作报告. 中国政府网, 2025.

[34] 张钹, 朱军, and 苏航. 迈向第三代人工智能. 中国科学: 信息科学, 50(9):1281–1302, 2020.

[35] 钟义信. 机制主义人工智能理论——一种通用的人工智能理论. 智能系统学报, 13(1):2–18, 2018.

[36] 刘永谋. 通用人工智能的复杂面孔. 哲学动态, (9), 2024.

[37] 赵汀阳. 人工智能的自我意识何以可能？. 自然辩证法通讯, 41(1), 2019.

[38] Lee J. Cronbach and Paul E. Meehl. Construct validity in psychological tests. *Psychological Bulletin*, 52(4):281–302, 1955.

[39] Hugh Zhang, Jeff Da, Dean Lee, Vasu Vaswani, Elmo Latefi, Giorgos Karamanolakis, Yichen Chen, et al. A careful examination of large language model performance on grade school arithmetic, 2024. GSM1k.

[40] Rylan Schaeffer, Brando Miranda, and Sanmi Koyejo. Are emergent abilities of large language models a mirage?, 2023. NeurIPS 2023 Outstanding Paper.

[41] Inioluwa Deborah Raji, Emily M. Bender, Alex Paullada, Emily Denton, and Alex Hanna. AI and the everything in the whole wide world benchmark, 2021. NeurIPS 2021 Datasets & Benchmarks; 正式版刊于 Critical AI.

[42] Andrew M. Bean, Ryan Othniel Kearns, Angelika Romanou, Franziska Sofia Hafner, Harry Mayne, Jan Batzner, Negar Foroutan, Chris Schmitz, Karolina Korgul, Hunar Batra, et al. Measuring what matters: Construct validity in large language model benchmarks, 2025. NeurIPS 2025 Datasets & Benchmarks.

[43] Tobi Salaudeen, Anka Reuel, Rowan Winter, Stephen Casper, Brian Domingue, Lucy Lu Wang, and Sanmi Koyejo. Measurement to meaning: A validity-centered framework for AI evaluation, 2025.

[44] Hanna Wallach, Meera Desai, Nicholas Pangakis, A. Feder Cooper, Angelina Wang, Solon Barocas, Alexandra Chouldechova, Chad Atalla, Su Lin Blodgett, Emily Corvi, et al. Evaluating generative AI systems is a social science measurement challenge, 2024. ICML 2025.

[45] Nathanael Jo and Ashia Wilson. What does your benchmark really measure? a framework for robust inference of AI capabilities, 2025. v2 改题为 “Position: AI Evaluations Should be Grounded on a Theory of Capability”.

[46] Ziang Xiao, Susu Zhang, Vivian Lai, and Q. Vera Liao. Evaluating evaluation metrics: A framework for analyzing NLG evaluation metrics using measurement theory, 2023. EMNLP 2023.

[47] Alec Mussgnug. AI operationalism: The case of international development. PhilSci-Archive, 26006, 2024. URL `https://philsci-archive.pitt.edu/id/eprint/26006/`.

[48] Max R. Bennett and Peter M. S. Hacker. *Philosophical Foundations of Neuroscience*. Blackwell, Oxford, 2003.

[49] Lauren van Till. The end of personification. *The American Journal of Bioethics*, 24(5):36–38, 2024. doi: 10.1080/15265161.2023.2278564.

[50] John F. Helliwell, Mauro J. Rossi, and Stephen J. Ball, editors. *Wittgenstein and Artificial Intelligence, Vol. I: Mind and Language*. Anthem Press, London, 2024.

[51] Chris Olah, Nick Cammarata, Ludwig Schubert, Gabriel Goh, Michael Petrov, and Shan Carter. Zoom in: An introduction to circuits. *Distill*, 2020. doi: 10.23915/distill.00024.001.

[52] Catherine Olsson, Nelson Elhage, Neel Nanda, Nicholas Joseph, Nova DasSarma, Tom Henighan, Ben Mann, Amanda Askell, Yuntao Bai, Anna Chen, et al. In-context learning and induction heads, 2022. Transformer Circuits Thread.

[53] Neel Nanda, Lawrence Chan, Tom Lieberum, Jess Smith, and Jacob Steinhardt. Progress measures for grokking via mechanistic interpretability, 2023. ICLR 2023.

[54] Jack Lindsey et al. On the biology of a large language model. Transformer Circuits Thread, Anthropic, 2025. URL https://transformer-circuits.pub/2025/attribution-graphs/biology.html.

[55] Yuxiao Li, Eric J. Michaud, David D. Baek, Joshua Engels, Xiaoqing Sun, and Max Tegmark. The geometry of concepts: Sparse autoencoder feature structure. *Entropy*, 27(4):344, 2025. doi: 10.3390/e27040344.

[56] Anthropic. Tracing the thoughts of a large language model. Anthropic Research Blog, 2025. URL https://www.anthropic.com/research/tracing-thoughts-language-model.

[57] Kayo Yin and Jacob Steinhardt. Which attention heads matter for in-context learning?, 2025. ICML 2025.

[58] Blakeney Leask, Michael Bussmann, Joseph Engels, Lawrence Sharkey, and Neel Nanda. Sparse autoencoders do not find canonical units of analysis, 2025. ICLR 2025.

[59] Nelson Elhage et al. Sparse crosscoders: Cross-layer sparse autoencoders for interpreting and comparing neural networks. Transformer Circuits Thread, Anthropic, 2024. URL https://transformer-circuits.pub/2024/crosscoders/index.html.

[60] John Hewitt and Percy Liang. Designing and interpreting probes with control tasks, 2019. EMNLP 2019.

[61] Yonatan Belinkov. Probing classifiers: Promises, shortcomings, and advances. *Computational Linguistics*, 48(1):207–219, 2022.

[62] Aleksandar Makelov, Georg Lange, and Neel Nanda. Is this the subspace you are looking for? an interpretability illusion for subspace activation patching, 2023.

[63] Grey Canby, Tom Davies, Piyush Rastogi, and Julia Hockenmaier. How reliable are causal probing interventions?, 2024.

[64] Erika Sullivan. Understanding from machine learning models. *The British Journal for the Philosophy of Science*, 73(1):109–133, 2022.

[65] Kathleen A. Creel. Transparency in complex computational systems. *Philosophy of Science*, 89(2):223–243, 2022.

[66] Lars Kästner. Explaining AI through mechanistic interpretability. *European Journal for Philosophy of Science*, 14(1):5, 2024. doi: 10.1007/s13194-024-00614-4.

[67] Iwan Williams, Ninell Oldenburg, Ruchira Dhar, Joshua Hatherley, Constanza Fierro, Nina Rajcic, Sandrine R. Schiller, Filippos Stamatiou, and Anders Søgaard. Mechanistic interpretability needs philosophy, 2025.

[68] Michael Ayonrinde and Austin Jaburi. A mathematical philosophy of explanations in mechanistic interpretability, 2025.

[69] Zezheng Lin and Fengming Liu. Position: Mechanistic interpretability must disclose identification assumptions for causal claims, 2026.

[70] Alethea Power, Yuri Burda, Harri Edwards, Igor Babuschkin, and Vedant Misra. Grokking: Generalization beyond overfitting on small algorithmic datasets, 2022.

[71] Vikrant Varma, Rohin Shah, Zachary Kenton, János Kramár, and Ramana Kumar. Explaining grokking through circuit efficiency, 2023.

[72] Boshi Wang, Xiang Yue, Yu Su, and Huan Sun. Grokked transformers are implicit reasoners: A mechanistic journey to the edge of generalization, 2024. NeurIPS 2024.

[73] Kihoon Park, Yjae Choe, and Victor Veitch. The linear representation hypothesis and the geometry of large language models, 2024. ICML 2024.

[74] Wes Gurnee and Max Tegmark. Language models represent space and time, 2024. ICML 2024.

[75] 朱松纯. 智能学科的源起、演进与趋势. 北京通用人工智能研究院, 2023. URL https://www.bigai.ai/blog/news/zdxk.

[76] 朱松纯. 什么时候才能出现人工智能的“中国时刻”？.《知识分子》访谈，北京大学中外人文交流研究基地转载, 2025. URL https://www.igcu.pku.edu.cn/info/1026/7115.htm.

[77] 谭铁牛. 人工智能的历史、现状和未来（全国人大常委会专题讲座）. 南京大学新闻网转载, 2018. URL https://www.nju.edu.cn/info/1055/485911.htm.

A 主张清单：逐字引语与表述强度

本清单收录正文诊断所依据的逐字引语，按两个板块排列：定义侧（操作主义与判据升格的诊断对象）与机制侧（部分谬误的诊断对象）。“出处层级”标注引语所在的话语层级；“强度”为本文的分级（纲领级、因果级、实现级、许可级、描述级、传播级）；“许可”一栏给出：按第 5 节协议，该引语可支撑何种主张。

A.1 定义侧

出处	引语	出处层级	强度	许可
Boring 1923[1]	“Intelligence as the tests test it”	标题	操作主义原型	仅作历史诊断对象
Legg & Hutter 2007[6]	“Intelligence measures an agent’s ability to achieve goals in a wide range of environments”	正文	定义级	方法层泛函 + 条件，非本体定义
Chollet 2019[7]	系统智能是技能获取效率的度量	摘要	定义级	方法层协议，附先验声明

出处	引语	出处层级	强度	许可
Morris 等 2023[3]	“at least as capable as a human at most tasks”	正文	认识层框架	分级工件，不含本体裁决
OpenAI 章程 [5]	“highly autonomous systems that outperform humans at most economically valuable work”	政策文本	方法层合同	经济替代证据，非通用性达成
Hendrycks 等 2025[4]	“matching the cognitive versatility and proficiency of a well-educated adult”	摘要	本体层声明	参照系声明，缺样本边界声明
Tesler 定理 [21]	“AI is whatever hasn’t been done yet”	短文	否定性类别	仅作移动边界的历史注脚

A.2 机制侧

出处	引语	出处层级	强度	许可
Olah 等 2020[51]	“Features are the fundamental unit of neural networks”	论文正文	纲领级	解释单位的纲领，未及能力定位
Olsson 等 2022（摘要）[52]	“preliminary and indirect evidence for a hypothesis that induction heads might constitute the mechanism”	摘要	许可级	假设级证据声明（合规样本）
Olsson 等 2022（正文）[52]	归纳头是小规模纯注意力模型中上下文学习的主要机制	正文（限定范围）	因果级	限定范围内机制归因
Nanda 等 2023[53]	“We fully reverse engineer the algorithm learned by these networks”；三阶段中的“电路形成”	摘要	实现级	玩具任务的实现证据
Varma 等 2023[71]	“延迟泛化”（grokking）源于记忆电路与泛化电路的竞争	摘要	因果级	合成设置的机制解释
Wang 等 2024[72]	“the formation of the generalizing circuit”	摘要	实现级	训练动力学主张
Lindsey 等 2025（正文）[54]	“attribution graphs provide hypotheses about mechanisms”；“existence proofs”	正文	许可级	认识层的自我设限（合规样本）
Anthropic 博客 2025[56]	“we found that Claude plans ahead”	机构博客	传播级	传播层强主张（诊断对象）
Tegmark 团队 2025[55]	“this concept universe has interesting structure at three levels”	摘要	描述级	几何描述，不作概念断言

出处	引语	出处层级	强度	许可
Park 等 2024[73]	“high-level concepts are represented linearly as directions”	摘要（非正式表述）	假说级	形式化假说 + 证据
Gurnee & Tegmark 2024[74]	标题断言 “Represent”，摘要降为 “suggest . . . basic ingredients of a world model”	标题/摘要	标题强、摘要弱	漂移样本
Yin & Steinhardt 2025[57]	上下文学习主要依赖功能向量头而非归纳头	摘要	实证反证	对强读法的反例
Leask 等 2025[58]	稀疏自编码器找不到规范的分析单元	标题	实证反证	特征非规范性的证据

清单的读法：机制侧前八行构成 “纲领 → 因果 → 实现 → 许可 → 传播” 的强度光谱，后五行是描述级、假说级、标题—正文漂移样本与实证反证。

B 中文语境对接

B.1 术语史时间线

1922–1924：比纳量表经修订进入中国，心理测量固定 “智力” 译名；1978–1981：“人工智能” 译名在大陆学界启用，中国人工智能学会筹建；2002–2003：北京大学设中国第一个智能科学系与 “智能科学与技术” 专业；2022：教育部学科目录将 “智能科学与技术” 列为交叉学科门类一级学科。“智力”（心理学）与 “智能”（智能科学）的分工沿用至今。

B.2 政策用词演变

政策用词演变的细节见第 2.5 节，此处记录要点：2017 年规划在基础理论布局中提及 “通用人工智能” [30]；2023 年北京政策把通用人工智能等同于通用大模型技术体系 [31]；以 2025 年政府工作报告为代表的中央文件改用 “人工智能 +”“具身智能”“智能经济” 等重点用词，未使用 “通用人工智能” [33]。政策语言的漂移与国际上的换词漂移（前沿模型、超级智能）同构：操作词汇绕开定义之争。

B.3 对话者定位

朱松纯团队的 “无限任务、自主定义任务、价值驱动” 三特征与通智测试 [32, 75, 76] 是中文语境最强的 AGI 定义体系——按本文的分层，属本体层声明与认识层工件；刘永谋的 “唯名论困境” [36] 是中文哲学侧对定义缺失的元批评，本文的类型论是对其 “困境” 的结构性回应（困境源于要求四类概念共用一种 “定义完成” 形态）；张钹的三代论 [34] 与谭铁牛的官方定义句式 [77] 分别提供历史分期与政策基准；钟义信的机制主义 [35] 给出信息论进路的智能定义，其 “本体论信息/认识论信息” 术语与本文三层框架相互呼应；赵汀阳 [37] 从主体性维度提出的 “新主体” 问题，在本文框架中落位于参照系概念的规范面。空白声明：以四词层次与边界为题的系统分析，中文文献未见；若存在，本文即以之为准并撤回空白主张。